

Treball final de grau

GRAU D'ENGINYERIA  
INFORMÀTICA

Facultat de Matemàtiques  
Universitat de Barcelona

Canviar  
el  
títol

---

Ciència de les dades aplicada a  
resultats acadèmics

---

Autor: Xavier Moreno Liceras

Directora: Laura Igual

Realitzat a: Departament

Matemàtica Aplicada y Anàlisis

Barcelona, 27 de juny de 2015

## **Abstract**

*This paper is part of an innovative educational project. Its main aim is to provide a support system for teachers, designed to help them when creating any student's profile. In order to create this intelligent system for teachers, data from Mathematics Faculty has been retrieved and analysed. This analysis focuses on student's profiles and score predictions. The profile analysis is based on previous years' grades as well as an average of how many students abandon their studies. On a side note, it develops also a score and grade prediction as well as a ranking of subjects, listed by level of difficulty depending on the student.*

## **Resum**

*Aquest treball està dins del marc d'un projecte d'innovació docent, en el que es proposa una eina de suport per al tutor d'estudis, la qual permeti ajudar al tutor a conèixer millor el perfil de cada alumne que tutoritza, realitzar el seguiment i aconsellar-lo. Per poder arribar a fer aquest sistema intel·ligent per al tutor d'estudis, s'ha realitzat un anàlisi basat en ciència de les dades sobre els resultats acadèmics de la Facultat de Matemàtiques. L'anàlisi es centra en l'exploració de perfils d'estudiants i en la predicció de notes. Dins de l'anàlisi de perfils d'estudiants es mira la taxa d'abandonament per cada perfil i la relació que té cadascun respecte els perfils del curs anterior. Per altra banda, es realitza un sistema de predicció de notes i un ranking d'assignatures ordenades per dificultat enfocat a l'alumne.*

## **Resumen**

*Este trabajo está dentro del marco de un proyecto de innovación docente, en el que se propone una herramienta de soporte para el tutor de estudios, la cual permita ayudar al tutor a conocer mejor el perfil de cada alumno que tutoriza. Para poder llegar a hacer este sistema inteligente para el tutor de estudios, se ha realizado un análisis basado en ciencia de los datos sobre los resultados académicos de la Facultad de Matemáticas. El análisis se centra en la exploración de perfiles de estudiantes i en la predicción de cualificaciones. Dentro del análisis de perfiles de estudiantes se mira la tasa de abandono para cada perfil i la relación que tiene cadauno respecto los perfiles del curso anterior. Por otro lado, se realiza un sistema de predicción de cualificaciones y un ranking de asignaturas ordenadas por dificultad enfocada al alumno.*

# Índex

<b>1</b>	<b>Introducció</b>	<b>1</b>
<b>2</b>	<b>Descripció del problema</b>	<b>3</b>
2.1	Projecte d'innovació docent . . . . .	3
2.2	Ciència de les dades . . . . .	3
2.3	Etapas del projecte . . . . .	4
2.3.1	Plantejament de preguntes . . . . .	5
2.3.2	Adquisició . . . . .	5
2.3.3	Neteja de dades . . . . .	5
2.3.4	Clusterització . . . . .	6
2.3.5	Predicció . . . . .	6
2.3.6	Evaluació . . . . .	6
2.4	Explicació de les dades obtingudes . . . . .	7
2.5	Preguntes plantejades . . . . .	8
2.5.1	Perfils d'estudiants . . . . .	8
2.5.2	Tassa d'abandonament per perfil . . . . .	8
2.5.3	Conservació de clusters . . . . .	8
2.5.4	Predicció de notes i ranking de dificultat d'assignatures . . . . .	9
<b>3</b>	<b>Planificació</b>	<b>10</b>
3.1	Tasques . . . . .	10
3.2	Diagrama de Gantt . . . . .	11
3.3	Evaluació econòmica . . . . .	12
<b>4</b>	<b>Desenvolupament del projecte</b>	<b>13</b>
4.1	Eines . . . . .	13
4.1.1	Eines de suport . . . . .	13
4.1.1.1	GitHub . . . . .	13
4.1.1.2	Bitbucket . . . . .	13
4.1.1.3	Trello . . . . .	13
4.1.2	Eines de programació . . . . .	14
4.1.2.1	Python . . . . .	14
4.1.2.2	Pandas . . . . .	14
4.1.2.3	NumPy . . . . .	14
4.1.2.4	Scikit-learn . . . . .	14
4.1.2.5	Bokeh . . . . .	14
4.1.2.6	Seaborn . . . . .	15
4.1.3	Eines d'edició . . . . .	15

4.1.3.1	IPython notebook . . . . .	15
4.1.3.2	Texmaker . . . . .	15
4.2	Tècniques utilitzades . . . . .	16
4.2.1	Clusterització (Agrupacions) . . . . .	16
4.2.1.1	<i>K-means</i> . . . . .	16
4.2.1.2	<i>Mean Shift</i> . . . . .	17
4.2.1.3	Mètriques utilitzades . . . . .	18
4.2.2	Predicció . . . . .	19
4.2.2.1	Recomanador . . . . .	19
4.2.2.2	<i>Random Forest Regressor</i> (RFR) . . . . .	23
4.2.2.3	Regressor lineal (LR) . . . . .	24
4.2.2.4	Mètriques utilitzades . . . . .	25
4.2.3	Reducció de dimensions . . . . .	27
4.2.3.1	PCA . . . . .	28
<b>5</b>	<b>Experiments i resultats</b>	<b>29</b>
5.1	Preparació previa als experiments . . . . .	29
5.2	Perfils d'estudiants . . . . .	30
5.3	Tassa d'abandonament per perfil . . . . .	41
5.4	Conservació de clusters . . . . .	43
5.5	Predicció de notes i ranking de dificultat d'assignatures . . . . .	46
5.5.1	Estratègia de validació . . . . .	47
5.5.1.1	Proves amb dades continues . . . . .	47
5.5.1.2	Proves amb dades discretes . . . . .	48
5.5.1.3	Proves amb ranking d'assignatures . . . . .	48
5.5.2	Resultats de les proves amb dades continues . . . . .	48
5.5.3	Resultats de les proves amb dades discretes . . . . .	51
5.5.4	Resultats de les proves amb ranking d'assignatures . . . . .	53
5.5.5	Proves qualitatives . . . . .	54
5.5.5.1	Resultats de les proves amb dades continues . . . . .	54
5.5.5.2	Resultats de les proves amb ranking d'assignatures . . . . .	56
<b>6</b>	<b>Conclusions</b>	<b>59</b>
6.1	Treball futur . . . . .	59

## 1 Introducció

Un dels components bàsics de l'activitat docent a la Universitat de Barcelona és l'acció tutorial, la qual té com a finalitat guiar i aconsellar a l'estudiant durant la seva etapa d'estudis. Ajuda a l'estudiant a millorar el seu rendiment, la seva orientació professional, i el més important, ajuda a prendre decisions que afavoreixin els seus resultats acadèmics i la seva satisfacció. El pla d'acció tutorial (PAT) en els graus de Matemàtiques i d'Enginyeria Informàtica a la Facultat de Matemàtiques realitza conjunt ordenat d'accions sistemàtiques prèviament planificades. Una de les coses que impulsa el PAT és l'assignació d'un tutor d'estudis a un grup d'estudiants. Un tutor d'estudis té com a finalitat, entre altres, acompanyar a l'alumnat durant el seu transcurs a la universitat des de l'inici del grau, fins al final, donant consell cara al món professional.

Ens hem trobat amb el problema que un tutor d'estudis al tutoritzar a un grup d'alumnes, no és capaç de contemplar detingudament cadascun d'aquests. Els pot guiar de forma genèrica, així seguint el pla d'acció tutorial. S'ha pogut observar al llarg dels anys, per exemple, que alumnes amb qualificacions moderades a primer i segon del grau d'Enginyeria Informàtica tenen problemes per afrontar certes assignatures de tercer. Això s'ha pogut observar al llarg dels anys, però i si estem perdent altres problemes o fets importants que no s'han pogut observar fins ara? És això el que volem explorar i fer conclusions que no s'hagin pogut arribar. Arran d'això, s'ha fet una petició al Vicerectorat de Política Docent per dur a terme un projecte que facilités el treball al tutor d'estudis. D'aquí neix un projecte d'innovació docent amb el títol de: *Sistema intel·ligent de suport per al tutor d'estudis*.

La finalitat del projecte d'innovació docent és la creació d'una eina que el tutor pugui consultar i li ajudi a prendre decisions cara a les seves tutories. Aquesta eina ha de permetre al tutor visualitzar la trajectoria d'un alumne, fer recomanacions específiques per cadascun d'ells, entre altres. Un dels recursos principals d'aquest projecte són les dades, ja que són la que ens permetran arribar a conclusions i poder construir l'eina per al tutor d'estudis. Les dades han sigut obtingudes a través del Vicerectorat de Política Docent.

Aquest treball final de grau forma part del projecte d'innovació docent, i es centra en l'estudi estadístic de les dades dels resultats acadèmics de la Facultat de Matemàtiques de la UB. L'objectiu és desenvolupar la base per poder ampliar, en la següent fase del projecte, el sistema per al tutor d'estu-

dis. En aquest treball ens hem centrat en l'exploració dels perfils d'estudiants dels primers cursos de cadascun dels graus impartits en la Facultat de Matemàtiques. També s'ha treballat en un sistema de predicció de notes d'un alumne cara a la seva pròxima matriculació. A més s'ha desenvolupat un ranking de dificultat de notes no matriculades d'un alumne a partir d'un predictor de notes. L'objectiu general d'aquest treball és obtenir coneixement a partir de les dades, i és per això que hem enfocat aquest projecte en un projecte de ciència de les dades.

## 2 Descripció del problema

### 2.1 Projecte d'innovació docent

Aquest treball de fi de grau, s'enmarca d'un projecte d'innovació docent [1] que va nèixer al Departament de Matemàtica Aplicada i Anàlisi (MAIA) i el Departament de Mètodes de Investigació i Diagnòstic en Educació (MIDE).

Com ja s'ha dit, la finalitat del projecte d'innovació docent és el desenvolupament d'un sistema intel·ligent de suport al tutor d'estudis, i per dur-lo a terme el projecte s'ha dividit en 5 fases.

**Fase 1** Adquisició, ordenació, centralització i anonimització de les dades curriculars disponibles dels alumnes. La fase inicial on es deixen les dades preparades per poder treballar amb elles.

**Fase 2** Anàlisi de les dades mitjançant tècniques de ciències de les dades. Fer un anàlisi estadístic de les dades que tenim i aplicar ciència de les dades per explorar la informació amagada darrere de les dades.

**Fase 3** Anàlisi de les dades mitjançant tècniques d'aprenentatge automàtic. A partir de les dades aplicar algoritmes de predicció de dades per poder predir les notes d'un alumne en base a les seves notes i la de la resta.

**Fase 4** Desenvolupament del sistema intel·ligent. En aquesta fase es busca el desenvolupament de la eina de suport per al tutor d'estudis.

**Fase 5** Avaluació. S'avalua el sistema per tal de fer proves, i buscar mancances i errors del propi sistema.

Aquest treball forma part de la fase 1, 2 i 3. Les fases 4 i 5 són l'altre part del projecte, i no s'en parlarà en aquest treball.

### 2.2 Ciència de les dades

La ciència de les dades és el conjunt d'etapes per tal d'arribar a un resultat, en forma de coneixement, a partir d'un conjunt de dades. Aquesta aplica un conjunt de tècniques de diferents àrees, com ara matemàtiques, estadística, teoria de la informació o tecnologia de l'extracció d'informació.

Un projecte de ciència de les dades es separa en diverses etapes:

1. **Plantejament de preguntes** Què és el que volem explorar? Té sentit el que ens estem plantejant?
2. **Adquisició de les dades** Com és la font d'obtenció de les dades? (Base de dades, *Web Scraping*, fitxer .csv)
3. **Descripció** Aquesta fase abasta tres processos
  - (a) **Neteja de dades** Com hem de netejar i separar les dades? (mostres atípiques, filtració, redució de dimensions, normalització, extracció de característiques)
  - (b) **Agregació** Com hem de recolectar i resumir les dades? (promig, desviació estàndard, box plots)
  - (c) **Enriquiment** Com podem afegir més informació a les nostres dades? (Cerca a altres fonts de dades addicionals)
4. **Descobriment** Podem segmentar les nostres dades per trobar grups naturals i disgregats? (Clusterització, visualització)
5. **Anàlisis** Com hem de modelar les nostres dades? (Com estan de relacionades cada variable?, Com podem determinar quines són les variables importants?)
6. **Predicció** A partir de les dades que tenim, que podem predir del futur? (Regresions, classificadors, recomanadors)
7. **Evaluació** Com de segurs estem dels nostres resultats? (Proves estadístiques, rendiment del model)

## 2.3 Etapes del projecte

A la secció anterior [secció: 2.2], s'han vist les etapes d'un projecte complet de ciència de les dades. Per aquest projecte s'han seguit les mateixes etapes, excepte la etapa d'anàlisis. En cada etapa es detalla que s'ha realitzat dins del context del projecte.



### 2.3.1 Plantejament de preguntes

La primera etapa és el plantejament de les preguntes que volíem resoldre. A partir de la plataforma trello (explicada en la secció d'eines), entre els participants del projecte vam plantejar preguntes, les quals entre tots decidíem amb quines preguntes ens quedariem i respondríem. Moltes de les preguntes no podíem saber si les podíem respondre fins que ens arribessin les dades, ja que depeníem totalment de la informació que contenien aquestes.

### 2.3.2 Adquisició

L'adquisició de les dades s'ha fet a partir del Vicerectorat de Política Docent. Aquest ens ha proporcionat les dades a través d'una fulla de càlcul. Tot i que les dades estan anonimitzades i tractades pel departament corresponent, s'ha hagut de fer una neteja de les dades.

### 2.3.3 Neteja de dades

En aquesta etapa hem hagut de netejar les dades per tal de poder treballar amb elles. Aquestes són les netejes realitzades:

**Canvi de format** Per poder manipular les dades amb més comoditat, es separara cada fulla de càlcul en un fitxer amb format *csv*, quedant un fitxer *csv* per taula. En la secció [2.4](#) s'explica amb detall l'obtenció de les dades.

**Canvi de nom de les columnes** Per poder creuar les diferents taules, els noms de les columnes han de ser el mateix.

**Enriquiment de les dades** A partir d'una font externa hem pogut adquirir el curs i semestre en que es cursa cada assignatura. Creuem aquestes dades amb les dades que tenim per tal de tenir més informació per assignatura.

**Unió de graus** L'any 2009 el grau en Enginyeria Informàtica de la UB té el codi *G1041*, però a partir de l'any 2010 el codi passa a ser *G1077*. Les assignatures són les mateixes, tot i que tenen codis diferents. S'ha fet la unió dels *G1041* amb *G1077*, per tal de no perdre informació rellevant, ni considerar-la per separat.

**Eliminació del curs 2014, segon semestre** Explorant les dades es pot veure que alumnes que s'han matriculat l'any 2014, però encara no han acabat de cursar l'assignatura, en aquesta els hi apareix un 0. Això fa que dintre

de les notes dels alumnes hi hagin dades incoherents, per aquesta raó s'ha procedit a eliminar totes les notes del segon semestre i de l'any 2014. El percentatge d'eliminació de dades és d'un 10.91% del total de notes.

**Normalització de les notes** Per tal d'evitar els canvis de mitja i variança en cada assignatura cursada per any, ja sigui per un canvi de professor, canvi de pla docent, diferents promocions, ... s'ha procedit a normalitzar les notes per any i per assignatura aplicant una normalització d'unitat tipificada [2] en la qual s'aplica per cada dada la següent fórmula:

$$z = \frac{x - \mu}{\sigma},$$

on  $\mu$  és el promig per any i per assignatura, i  $\sigma$  és la desviació estàndard per any i per assignatura. Amb això aconseguim mitja 0 i desviació estàndard 1.

#### 2.3.4 Clusterització

Aquesta etapa és necessària per poder respondre a una des de les preguntes plantejades, i és: *Hi ha diferents perfils d'alumnes?* [secció: 5.2]. Per tal de respondre a aquesta pregunta s'han aplicat mètodes de clusterització a partir de les notes dels alumnes diferenciats per cursos.

#### 2.3.5 Predicció

Es realitza la predicció on s'ha volgut predir les notes que pot arribar a treure un alumne en base a les notes que ha tret en cursos anteriors.

#### 2.3.6 Evaluació

Un cop construïda la predicció, hem d'avaluar quant de bona és. S'ha evaluat de forma quantitativa (mitjançant mètriques) i qualitativament (amb la mostra de casos).

## 2.4 Explicació de les dades obtingudes

En aquest apartat s'explicarà la informació més rellevant que podem trobar en les nostres dades. Recordem que les dades les tenim en forma de fulla de càlcul, i aquesta l'hem separat per diversos fitxers, amb format .csv.

Les dades que hem pogut adquirir són molt enriquidores, tenen la informació necessària per fer un estudi ampli tant per als estudiants com per a l'estudi d'assignatures. A més les dades venen anonimitzades, a priori no podem obtenir la informació d'un alumne que coneguem. Les dades les tenim separades en diferents fitxers, els quals estan relacionats entre si mitjançant identificadors, com ara un identificador d'alumne o el codi d'una assignatura. Els fitxers són els següents:

**Informació general de l'estudiant** Aquest fitxer conté per cada fila informació sobre un alumne en termes de matriculació: l'any d'inici de carrera, grau que realitza, la via amb la qual va accedir a la carrera, la nota d'accés a la Universitat, entre altres.

**Informació d'assignatures** Aquí trobem la informació de cada assignatura que existeix en els graus d'Enginyeria Informàtica i matemàtiques. Cada fila presenta la següent informació: l'identificador de l'assignatura, el nom de l'assignatura, els crèdits ECTS corresponents a aquesta i el grau a la que pertanyen. A banda d'aquestes dades, s'ha obtingut altra font d'informació d'assignatures, on per cada assignatura detalla de quin curs i semestre es tracta. Aquesta dada s'ha creuat amb l'anterior per ampliar la informació per assignatura.

**Qualificacions per alumne i per assignatura** Per últim i més important, tenim el fitxer que conté les qualificacions de tots els alumnes per assignatura, és a dir, per cada fila podem observar: l'identificador de l'alumne que realitza l'assignatura, l'identificador de l'assignatura realitzada, la qualificació d'aquella assignatura, l'ensenyament del qual es tracta, l'any en el que es va realitzar l'assignatura i el tipus d'apunt (ordinaria, reconeixement o convalidada).

## 2.5 Preguntes plantejades

### 2.5.1 Perfils d'estudiants

La primera pregunta plantejada és: *Hi ha diferents perfils d'alumnes?* A partir de la distribució de les notes de cada alumne per cada assignatura que ha fet, podem determinar que hi ha diferents perfils d'estudiants? Això és el que ens estem preguntant. S'han agafat tots els alumnes que hagin cursat totes les assignatures de primer i després les de segon, tant al grau d'Enginyeria Informàtica com al grau de Matemàtiques. La experiència ens diu que hi han alumnes bons en programació i dolents en les assignatures de matemàtiques a primer del grau d'Enginyeria Informàtica. Però per a la resta de cursos, quins perfil podem trobar? Ara que tenim les dades això ho podem saber, convertirem les dades en coneixement.

### 2.5.2 Tassa d'abandonament per perfil

La pregunta proposada és: *Quina és la tassa d'abandonament per cada tipus de perfil?* A partir dels perfils que han sigut determinats en la pregunta anterior, quin és el percentatge d'abandonament per cadascun d'aquests? Volem saber si és cert que els alumnes que van a parar al perfil d'alumnes que ho suspenen tot són els que solen abandonar la carrera. Fins ara això és el que podem saber a partir de l'experiència, però es pot demostrar amb dades i corroborar-ho.

### 2.5.3 Conservació de clusters

Al llarg dels anys s'ha pogut notar que els alumnes que solen treure bones notes a primer d'Enginyeria Informàtica, acaben treien bones notes a segon la gran majoria. Per això ens vam plantejar la següent pregunta: *Amb quin perfil de provinença encaixa cadascun d'aquests perfils?* Ara bé, això és cert? Per això ens plantegem aquesta pregunta, a partir de perfils d'origen, volem saber amb quin perfil de destí solen dirigir-se. En aquest cas hem fet els següents creuaments per cada grau:

Origen	Destí
Via d'accés	Perfil d'alumnes de primer
Perfil d'alumnes de primer	Perfil d'alumnes de segon

Els perfils d'alumnes de primer i segon són els perfils determinats a la primera pregunta, i els perfils de via d'accés que hem seleccionat han sigut els següents:

1. Batxillerat (Batx)
2. Salt d'Universitat (Uni)

S'ha obviat als alumnes provinents de cicle o ja diplomants, per la seva baixa presència. Les vies d'accés només les comprovem amb els alumnes que hagin cursat totes les assignatures de primer, sense convalidar, el que fa que no aparegui una gran quantitat d'alumnes de cicle formatiu, ja que la majoria d'aquests tenen alguna assignatura convalidada a primer. Pel que fa als alumnes ja diplomats, no hi han masses en les dades presents.

#### **2.5.4 Predicció de notes i ranking de dificultat d'assignatures**

A partir de les notes que ha tret un alumne en el seu passat, podem predir quines assignatures li aniran bé i malament en el futur? Bé, això és el que ens plantejem en aquesta última pregunta, volem recomanar a un alumne en quines assignatures no li aniran gaire bé per a que així el tutor d'estudis recomani a l'alumne reforçar més el temari que es donarà en aquella assignatura. A més, es realitza un ranking d'assignatures per cada alumne, que determina la dificultat d'aquestes. D'aquesta manera el tutor podrà donar uns consells o uns altres, depenent de l'ordre present de les assignatures en el ranking.

## 3 Planificació

### 3.1 Tasques

Les tasques d'aquest projecte són semblants a les etapes d'un projecte de ciència de les dades. Les tasques són:

- Formació
- Plantejament de preguntes
- Neteja de dades
- Clusterització
- Predicció
- Evaluació
- Documentació

Les úniques etapes noves que trobem són: la de formació, és la etapa dedicada l'aprenentatge autònom de les eines utilitzades; la de documentació, és el període de temps per tal de desenvolupar aquesta memòria.

### 3.2 Diagrama de Gantt

S'ha construït dos diagrames de Gantt, un a partir de la planificació inicial [Figura: 1] i l'altre amb la planificació real [Figura 2] per tal de veure les diferències.

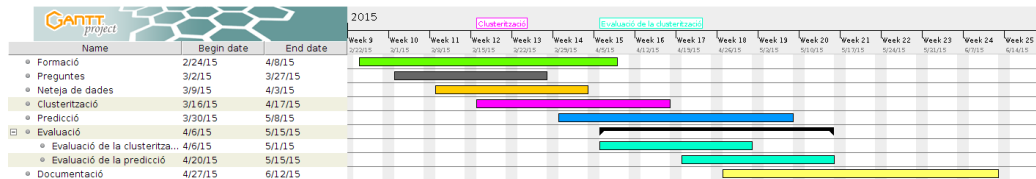


Figura 1: Planificació inicial

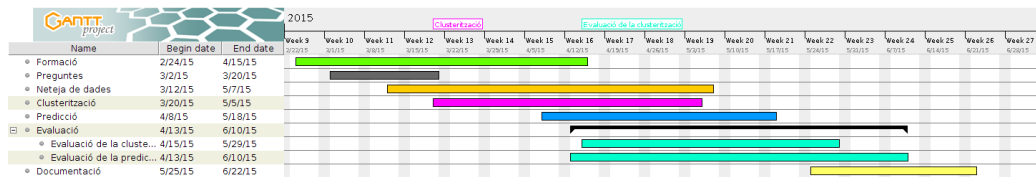


Figura 2: Planificació real

S'observa que s'ha pogut seguir la planificació inicial, tot i que en el cas de la neteja de dades s'ha allargat el temps. Això és degut a la espera de noves revisions de dades a través del Vicerectorat de Política Docent.

El Treball de fi de Grau equival a 18 crèdits ECTS, si cada crèdit equival a 25 hores, llavors tenim:

$$18 \text{ crèdits} \cdot \frac{25 \text{ hores}}{1 \text{ crèdits}} = 450 \text{ hores}$$

Per tant totes les tasques s'han de realitzar en 450 hores, les hores dedicades han sigut les següents:

	Formació	Preguntes	Neteja de dades	Clusterització	Predicció	Evaluació	Documentació
Hores	25	25	50	75	75	125	50

Taula 1: Hores de dedicació per cada tasca

### 3.3 Evaluació econòmica

	Hores	Preu per hora (Euro)	Preu total (Euro)
Formació	25	0	0
Plantejament de preguntes	25	10	250
Neteja de dades	50	20	1000
Clusterització	75	25	1875
Predicció	75	25	1875
Evaluació	125	25	3125
Documentació	75	0	0
<b>TOTAL</b>	<b>450</b>		<b>8125</b>

Taula 2: Taula d'evaluació econòmica

El projecte sortiria per 8125 euros, en els quals s'inclou en la etapa de Evaluació, una documentació dels resultats obtinguts i les conclusions d'aquests.



## 4 Desenvolupament del projecte

### 4.1 Eines

#### 4.1.1 Eines de suport

Aquestes són les eines de suport que ens han ajudat al llarg del treball per tal de fer més còmode la seva organització tant personal com per equip.

##### 4.1.1.1 GitHub

GitHub [3] és una plataforma online per desenvolupar projectes software de forma col·laborativa. Aquesta plataforma utilitza un control de versions anomenat Git. La finalitat de GitHub és l'emmagatzemament massiu de projectes amb codi font obert. Per això hem optat per la utilització de GitHub, ja que que volem que el nostre codi el pugui veure tothom i que qualsevol que el necessiti per fer la seva investigació, el pugui utilitzar.

##### 4.1.1.2 Bitbucket

Bitbucket [4] és una plataforma semblant a GitHub, però amb el servei d'un altre control de versions com Mercurial a més de Git. Bitbucket té l'avantatge de permetre crear repositoris privats de forma gratuïta. Aquesta plataforma va bé per a l'inici d'un projecte on es fan molts canvis en el codi, ja que pots tenir el codi en privat, i un cop el codi ja agafa forma es pot migrar a GitHub. Això és el que hem fet nosaltres en el projecte, començar amb Bitbucket i després passar-nos a GitHub amb el codi font obert.

##### 4.1.1.3 Trello

Per últim com eina de suport, hem fet servir Trello [5], una plataforma online que permet una comunicació més clara entre els membres d'un projecte. Amb Trello pots crear projectes i cada projecte conté un conjunt de llistes que s'omplen de tasques. Hem fet servir Trello per comunicar-nos amb la tutora i tenir present una planificació per tal d'organitzar-nos millor.

### 4.1.2 Eines de programació

En aquesta secció trobarem amb el llenguatge de programació, i conjunt de llibreries, que hem treballat.

#### 4.1.2.1 Python

Python [6] és un llenguatge d'alt nivell interpretat. Remarquen molt la fàcil lectura del seus codis, per això té una sintaxis molt semblant a un pseudocodi. Python és un llenguatge de codi obert i desenvolupat per *Python Software Foundation*, una organització sense ànim de lucre. Vam escollir Python per dues raons: per ser un llenguatge de scripting i per la seves llibreries relacionades amb el tractament de dades (com [Pandas](#), [NumPy](#) o [Scikit-learn](#)).

#### 4.1.2.2 Pandas

Pandas [7] és una biblioteca informàtica escrita en Python per a la manipulació i anàlisi de dades. Especialment va bé per al tractament de taules alhora de fer consultes, o per a l'agrupació i agregació d'informació.

#### 4.1.2.3 NumPy

Numpy [8] és una biblioteca informàtica de Python per operar amb vectors i matrius d'una forma més extensa a la que et permet el mateix llenguatge Python, la qual conté tot un conjunt de funcions matemàtiques d'alt nivell per treballar amb aquests vectors i matrius.

#### 4.1.2.4 Scikit-learn

Scikit-learn [9] (o sklearn) és una biblioteca informàtica orientada a l'aprenentatge automàtic per a Python. Té suport per classificadors, regressors i clusterització. Per aquest projecte hem fet servir clustering i regressors. En la secció de [Tècniques utilitzades](#) es detalla cada tècnica utilitzada d'aquesta biblioteca informàtica.

#### 4.1.2.5 Bokeh

Bokeh [10] és una biblioteca informàtica per a la visualització interactiva de dades dirigida als navegadors per a la seva presentació a través d'HTML i JavaScript. Bokeh té el suport per a gràfiques específiques com diagrames de barra, box plots o time series, però a banda d'aquests gràfics pots dibuixar sobre un gràfic amb elements bàsics com cercles, línies, rectangles, entre altres.

#### 4.1.2.6 Seaborn

Per últim tenim Seaborn [11] que també és una biblioteca informàtica per a visualització de dades com Bokeh, amb gràfiques específiques per a la visualització de resultats estadístics. A més té una part dedicada a les paletes de colors i la qual permet escollir un conjunt de colors afavorits per mostrar les dades.

#### 4.1.3 Eines d'edició

##### 4.1.3.1 IPython notebook

Ipython notebook [12] és un editor per a l'entorn de Python. La filosofia *notebook* s'emprea per tenir un codi molt més llegible i a més tenir explicacions d'allò que es programa, ja que es pot barrejar codi, la sortida del codi, markdown, HTML, entre altres. Hem optat per escollit aquest entorn d'edició ja que en un projecte de ciència de les dades s'han de veure resultats constants i poder-los comentar.

##### 4.1.3.2 Texmaker

Texmaker [13] és una eina d'edició de  $\text{\LaTeX}$ , la qual permet poder generar informes, documents, llibres d'una forma més programàtica. A partir d'un etiquetatge estipulat es poden generar documents amb un estil predefinit com el d'aquesta memòria.

## 4.2 Tècniques utilitzades

A continuació es presenten les tècniques i mètriques de clusterització i predicció de dades utilitzades en aquest projecte. La finalitat és proporcionar un coneixement per poder passar a la secció de *Experiments i resultats* [secció: 5].

### 4.2.1 Clusterització (Agrupacions)

La clusterització és molt important en el món de les dades, permet reconèixer diferents grups de ítems de les nostres dades, en el nostre cas d'alumnes. Per això, abans de veure els resultats i experiments explorats, cal entendre les diferències entre les diferents tècniques de clusterització. En aquest projecte hem fet servir dues tècniques, on l'objectiu d'elles és el mateix, desfragmentar les dades i trobar diferents grups d'alumnes. Aquestes dues tècniques són K-means i MeanShift, ambdues implementades en la biblioteca informàtica de Scikit-learn.

#### 4.2.1.1 *K-means*

*K-means* [14] probablement és un dels algorismes d'agrupació més conegut. Partint de  $n$  elements, divideix aquests  $n$  elements en  $k$  grups (argument obligatori de l'algoritme) on cada element pertany al grup més proper a la mitjana. L'algoritme de *K-means* està descrit per la següent fórmula:

Tenint un conjunt d'elements  $(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n)$  on cada element és un vector  $d$  dimensional, *K-means* construeix una partició dels elements en  $k$  grups, on  $k \leq n$  quedant  $\mathbf{S} = \{S_1, S_2, \dots, S_k\}$ . Amb la finalitat de minimitzar la suma dels quadrats dintre de cada grup:

$$\arg \min_{\mathbf{S}} \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \mu_i\|^2$$

on  $\mu_i$  és el centroide dels punts del conjunt  $S_i$ , és a dir, el punt mig.

Com es veu en la fórmula, aquest algoritme depèn d'una  $k$ , per determinar agrupacions, per tant *K-means* ha de rebre com paràmetre d'entrada quants grups busquem. També podem pensar que depèn del centroide  $\mu_i$ , però no es necessari, ja que aquest convergeix si s'apliquen  $x$  iteracions sobre la fórmula.

#### 4.2.1.2 *Mean Shift*

*Mean Shift* [15] és l'altre tècnica d'agrupació o clusterització que utilitzo en aquest projecte. L'objectiu d'aquesta tècnica és el mateix que *K-means*, però el seu algoritme funciona de forma diferent, considerant l'espai de característiques com una funció de densitat de probabilitat.

Aquest algoritme no necessita com a entrada el número de clusters que busquem, com *K-means*. Té altres paràmetres d'entrada, però són opcionals. En aquesta imatge podem veure la diferència entre *K-means* i *Mean Shift*.




Figura 3: Comparació de K-means amb Mean Shift [16]

Com es veu en la figura d'adalt, en el tercer gràfic de cada tècnica, tenim que amb *MeanShift*, com no hem de dir el número de divisions que volem, ell mateix ens diu que hi han tres grups. Però amb *K-means* si possem dos clusters, per exemple, estariem unificant dos clusters en un.

#### 4.2.1.3 Mètriques utilitzades

Existeixen dos indicadors d'avaluació dels resultats de l'anàlisi:

1. **Supervisat** Utilitza les agrupacions reals per comparar-les amb les agrupacions donades per l'algoritme de clusterització.
2. **No supervisat** És tot lo contrari, mesura la qualitat del propi model, basant-se en les característiques d'aquest.

En el nostre cas, el que volem és explorar i averiguar quins perfils d'estudiants hi han, per tant hem d'utilitzar mètriques no supervisades, ja que no tenim una referència per comparar. La única mètrica no supervisada que utilitzem és la *Silhouette*.

**Silhouette** [17] és una mesura no supervisada, que valora la integrat de cada node dintre d'un cluster. Per cada punt (o observació) calculem la *silhouette* amb la següent fórmula:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

on:

$i$  és el punt del qual volem calcular la *silhouette*.

$a(i)$  és la distància mitja als demés punts dintre del cluster de  $i$ .

$b(i)$  és la distància mitja als punts que no estan dintre del cluster de  $i$ .

Un cop tenim la *silhouette* calculada per cada observació, per tenir la *silhouette* del cluster, fem la mitja de totes elles.

$$\text{silhouette}_g = \frac{1}{n} \sum_{j=1}^n \text{silhouette}_i$$

### 4.2.2 Predicció

La etapa de predicció és important en un projecte de data science, ja que ens permet predir el futur d'una forma estadística en base a les observacions que tenim. Però igual que la clusterització, hi han diverses tècniques, aquí explicaré quines tècniques hem utilitzat per aquest projecte.

Un predictor és un algoritme que pasat un conjunt de dades d'entrenament, és capaç de poder predir dades del futur. En el nostre cas, per exemple entrenem als predictors amb les notes de primer i segon de carrera. Llavors si li pasem un alumne amb les notes de primer, el predictor ens podrà predir quines seran les seves notes de segon basant-se en les dades que li hem passat per entrenar.

#### 4.2.2.1 Recomanador

Una de les tècniques per predir dades són els recomanadors. En aquest apartat explicaré com funciona el recomanador que he montat passant-nos en context del nostre projecte. Tenint en compte les notes d'un conjunt d'alumnes, el recomanador és capaç de predir de forma estadística les notes d'un alumne en base a la resta dels altres.

Imaginem que tenim una matriu tal que:

$$C = \begin{matrix} & a_1 & a_2 & \cdots & a_m \\ \begin{matrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{matrix} & \begin{pmatrix} c_{11} & ? & \cdots & c_{1m} \\ c_{21} & c_{22} & \cdots & ? \\ \vdots & \vdots & \ddots & \vdots \\ ? & c_{n2} & \cdots & c_{nm} \end{pmatrix} \end{matrix}$$

on:

$e_i$  és un estudiant.

$a_i$  és una assignatura.

$c_{ij}$  és la nota d'un estudiant  $i$  en una assignatura  $j$ .

$?$  són notes no completes, perquè un alumne no ha cursat l'assignatura.

La finalitat del nostre recomanador, és omplir les notes que apareixen amb  $?$  i passar la nota més adient. Abans d'explicar com funciona, introduiré els diferents tipus de recomanadors que podem tenir:

**Recomanador col·laboratiu bassat en estudiant (RCxE)** Prediem la nota d'un alumne en base a la semblança de l'alumne amb la resta. És a dir, si un alumne  $e_i$  té unes notes semblants a un alumne  $e_j$ , les assignatures que no ha cursat  $e_i$  podrem dir que seran semblants a les notes que ha tret  $e_j$  en aquelles assignatures.

**Recomanador col·laboratiu bassat en assignatures (RCxA)** Ara en comptes de bassar-nos en la semblança entre els estudiants, ens basem en la semblança entre una assignatura amb la resta. És a dir, si una assignatura  $a_i$  segueix una distribució semblant a una assignatura  $a_j$ , llavors podem dir que un alumne  $e_i$  treurà una nota semblant en ambdues assignatures.

**Recomanador híbrid** Per últim tenim la barreja dels dos recomanadors esmentats, aplicant un pes d'importància a cadascun. Aquest recomanador no s'ha fet servir en aquest projecte, però es podria fer servir si es pogués aprendre quin pes assignar a cada tipus de recomanador.

Començaré explicant el recomanador col·laboratiu bassat en l'estudiant, el qual agafaré com a base per explicar el bassat en assignatures. Imaginem que tenim una matriu semblant a la d'abans:

$$C = \begin{matrix} & a_1 & \cdots & a_q & \cdots & a_m \\ \begin{matrix} e_1 \\ \vdots \\ e_p \\ \vdots \\ e_n \end{matrix} & \begin{pmatrix} c_{11} & \cdots & \mathbf{c_{1q}} & \cdots & ? \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ ? & \cdots & ? & \cdots & c_{pm} \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ c_{n1} & \cdots & \mathbf{c_{nq}} & \cdots & c_{nm} \end{pmatrix} \end{matrix}$$

El que volem és predir la nota que té el símbol ? en negreta a la posició  $c_{pq}$ . El que necessitem és aplicar a la posició que volem predir la següent fórmula:

$$c_{pq} = \sum_{i=1}^n \alpha_{e_p e_i} c_{iq}$$

on:

$\alpha$  és una funció de similitud, que dóna pes a  $c_{a_q e_j}$ .

$e_i$  és un estudiant.

$a_i$  és una assignatura.



Amb aquesta fórmula podem veure la funcionalitat d'aquest recomanador, si ens fixem, com més semblants siguin dos estudiants, més pes li donarem a la nota que ha tret un dels dos per recomanar-li a l'altre. Aquesta fórmula és la fórmula d'una mitja ponderada.

Ara bé, si el que volem és fer un recomanador basat en assignatures, tenim dues opcions. O bé aplicar la següent fórmula:

$$c_{pq} = \sum_{j=1}^n \alpha_{a_q a_j} c_{pj}$$

O bé, fer la transposada de la matriu anterior i aplicar la mateixa fórmula d'abans.

Per construir aquest recomanador s'ha de modelar seguint l'interfaç dels predictors de la biblioteca informàtica de *Scikit-learn*. Un predictor en *sklearn* ha de tenir un mètode *fit* i un altre que sigui *predict*. En la figura 4 es pot veure el fluxe de les crides a les funcions.

```
from sklearn.linear_model import LinearRegression
# Definim les variables
X = [(1,2,3), (5,3,2), (3,1,0), (123,433,452), (233,231,786)]
# Fem el promig per cada Xi
y = [2, 3.33, 1.33, 336, 416]
# Definim una nova variable
x = (45,34,65) # promig = 48
# Creem un predictor
predictor = LinearRegression()
predictor.fit(X,y)
print predictor.predict(x)
# >> 47.9271056831
```

Figura 4: Fluxe de crides de funcions d'un predictor d'sklearn

Primer s'ha de cridar al mètode *fit* i seguidament ja podem cridar al mètode *predict* tantes vegades com volguem per predir.

```
class Recommender(BaseEstimator):
    def __init__(self, method=coefPearson, transpose=False):
        self._m = None
        self._method = method
        self._transpose = transpose

    def fit(self, X, y):
        # ...
        return self

    def predict(self, X):
        # ...
        return predicted
```

Figura 5: Estructura del recomanador col·laboratiu

En la figura 5 trobem l'estructura del recomanador col·laboratiu que s'ha construït seguint les fórmules explicades en la secció de Recomanadors. El constructor accepta per paràmetre la funció de similitud entre items (per defecte el coeficient de pearson), i un booleà que determina si és un Recomanador col·laboratiu basat en alumnes (*transpose=False*) o un Recomanador col·laboratiu basat en assignatures (*transpose=True*).

#### 4.2.2.2 *Random Forest Regressor* (RFR)

Abans d'explicar la tècnica de *Random Forest Regressor*, s'ha d'entendre el concepte d'un arbre de regressió. Un arbre de regressió és una tècnica utilitzada en aprenentatge automàtic, que es defineix com un model predictiu que mapeja observacions sobre una característica a conclusions sobre el valor objectiu d'aquesta característica. En aquestes estructures d'arbre, les fulles representen un valor real d'aquella característica i les branques les conjuncions de característiques que han portat fins a la fulla.

*Random Forest Regressor* [19] és un conjunt d'arbres de regressió, on el resultat és la mitja de la sortida de cada arbre, a més per a cada arbre s'aplica un soroll aleatori a les dades sense variar en la seva distribució, això fa que es beneficiï al fer la mitja.

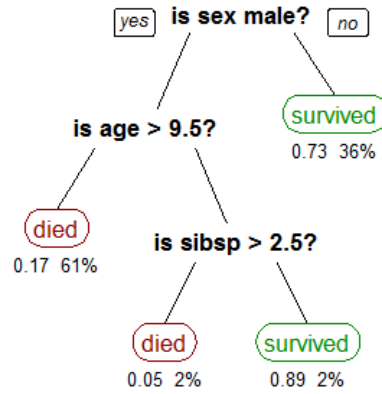


Figura 6: Exemple d'arbre de decissió [18]

#### 4.2.2.3 Regressor lineal (LR)

Un regressor lineal [20] modelitza una recta de regressió a partir d'un núvol de punts. La recta definida, és la recta més propera que passa per tots els punts. El que busca és definir una variable dependent a partir d'un conjunt de variables, és a dir:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \varepsilon$$

on  $\beta_i$  són termes constants i  $n$  són els conjunts d'observacions que tenim. En el cas d'una sola variable dependent, tindriem un resultat semblant al de la figura 7.




Figura 7: Regressió lineal [21]

#### 4.2.2.4 Mètriques utilitzades

Igual que en la secció de clusterització, per a la predicció de dades, també hem utilitzat mesures per validar les nostres prediccions. Aquí hem utilitzat mesures supervisades. Anomenem  $y_{pred}$  al conjunt de qualificacions que s'ha predit d'un alumne, i  $y_{test}$  al conjunt de qualificacions real del estudiant.

**Error promig absolut (MAE)** L'error promig absolut [22] una mesura supervisada que és basa en fer la mitja dels errors produïts pel predictor. Està definit per la següent fórmula:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_{pred_i} - y_{test_i}|$$

**Error promig quadràtic (MSE)** Per un altre banda tenim una segona mètrica, l'error promig quadràtic [23], supervisada també. Aquesta mètrica penalitza els error alts, ja que la diferència es elavada al quadrat, quedaria la següent fórmula:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_{pred_i} - y_{test_i})^2$$

**Coefficient de pearson (PCC)** El coeficient de pearson, l'utilitzem com una mètrica supervisada i la fem servir per mesurar la diferencia de la distribució de les notes predites amb les notes reals. El coeficient de pearson està definit per la següent fórmula:

$$\text{PCC} = \left| \frac{\sum_{i=1}^n (y_{pred_i} - \bar{y}_{pred_i})(y_{test_i} - \bar{y}_{test_i})}{\sqrt{\sum_{i=1}^n (y_{pred_i} - \bar{y}_{pred_i})^2 \sum_{i=1}^n (y_{test_i} - \bar{y}_{test_i})^2}} \right|$$

**Desviació estàndard (std)** També calculem la desviació estàndard per veure si els errors són més o menys dispersos. La fórmula utilitzada és la següent:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (|y_{pred_i} - y_{test_i}| - \mu)^2}$$

***Mean Ranking Score (MRS)*** Aquesta és una tècnica desenvolupada per nosaltres, està basada en la mesura de *Error promig absolut*, però amb valors discrets. És una mesura supervisada per tal de mesurar quant de bo és un ranking que s'hagi predit. Es tracta d'una mitja a partir de les distàncies d'error en el ranking. La mètrica presenta la següent fórmula:

$$\text{MRS} = \frac{1}{n} \sum_{i=1}^n |\gamma(y_{pred_i}) - \gamma(y_{test_i})|$$

on:

$\gamma$  és una funció que ens retorna la posició de l'element en el ranking

La millor manera d'entendre aquesta mètrica és mostrar un exemple a partir d'aquesta taula:

Ranking Real	Ranking Predit
A1	A4
A2	A2
A3	A1
A4	A3

Taula 3: Exemple de rankings

Per aquest exemple, hauriem de recórrer els 4 elements:

$$|\gamma(A1_{notes_r}) - \gamma(A1_{notes_p})| = |1 - 3| = 2$$

$$|\gamma(A2_{notes_r}) - \gamma(A2_{notes_p})| = |2 - 2| = 0$$

$$|\gamma(A3_{notes_r}) - \gamma(A3_{notes_p})| = |3 - 4| = 1$$

$$|\gamma(A4_{notes_r}) - \gamma(A4_{notes_p})| = |4 - 1| = 3$$

Quedant:

$$\text{MRS} = \frac{2 + 0 + 1 + 3}{4} = \frac{6}{4} = 1.5$$

Ens podem fixar que si comparem dos rankings iguals, llavors  $\text{MRS} = 0$ . Per tant, com més proper estigui a 0, millor s'aproparà la predicció del ranking real.

Totes aquestes mètriques són necessàries per evaluar cada tècnica de predicció que utilitzo. Tot i així, les tècniques més importants i que tenen més pes són l'error promig absolut i quadràtic.

### 4.2.3 Reducció de dimensions

Una de les últimes tècniques que utilitzo en aquest projecte d'innovació docent és la reducció de dimensions. És imprescindible per poder visualitzar les teves dades si tenen una dimensió major que 3. Aquestes tècniques a més permeten reduir el cost computacional sense variar en el seu resultat. Una de les tècniques utilitzades en aquest projecte és l'anàlisi de components principals (PCA).

#### **4.2.3.1 PCA**

L'anàlisi de components principals o PCA [\[24\]](#) el que fa és escollir un nou sistema de coordenades a partir d'una transformació lineal on s'ordenen les variàncies per mida. La variància amb major mida s'escollirà com eix principal, la segona variància com a segon eix, així successivament fins obtenir la dimensionalitat escollida per argument.



## 5 Experiments i resultats

En aquest apartat s'explicarà pas per pas els experiments realitzats i els resultats obtinguts per cada pregunta plantejada a la secció [sec:2.5]. Fins ara s'han presentat tots els conceptes necessaris per poder entendre aquesta secció. Primer es mostren les preguntes relacionades amb la clusterització i es finalitza amb els resultats obtinguts amb la predicció de notes.

### 5.1 Preparació previa als experiments

Abans de començar a comentar els resultats, explicaré de quines dades parteixo per respondre cada pregunta. D'inicial tenim tota una taula on cada fila és la qualificació d'un alumne donada un assignatura, per tant en cada fila tenim informació com *l'identificador d'alumne, assignatura, tipus d'apunt (convallada, ordinaria o de reconeixement), qualificació de l'assignatura, ...* És a partir d'aquesta taula que fem una conversió de tal manera que en cada fila ens quedi un alumne i cada columna sigui una assignatura, construint una matriu tal que així:

$$C = \begin{matrix} & a_1 & a_2 & \cdots & a_m \\ \begin{matrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{matrix} & \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1m} \\ c_{21} & c_{22} & \cdots & c_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nm} \end{pmatrix} \end{matrix}$$

on:

$e_i$  és un estudiant.

$a_j$  és una assignatura.

$c_{ij}$  és la nota de l'alumne  $i$  donada una assignatura  $j$ .

$C \in \mathbb{R}^{n \times m}$  on  $0 \leq c_{ij} \leq 10$ , la matriu no conté cap nombre desconegut i que cada alumne  $e_i$  ha cursat tot el conjunt d'assignatures  $\{a_1, a_2, a_3, \dots, a_m\}$ .

El conjunt d'assignatures que apareixen en les columnes pot variar dependent de la pregunta que volem respondre, pot ser el conjunt d'assignatures de primer, com el conjunt de les de primer més les de segon. Però a partir d'una matriu  $C$  com aquesta em basaré algunes qüestions.

## 5.2 Perfils d'estudiants

La resposta a la pregunta: *Hi ha diferents perfils d'alumnes?* és trobar diferents tipus d'estudiants en relació a la seva nota. Alumnes amb notes molt bones en tot, alumnes amb males notes en certes assignatures, alumnes que suspelen, entre altres. Però volem que el nostre algoritme explori els grups que poden haver-hi de forma no supervisada, és a dir, sense indicar-li quins són els grups a priori.

Com el que busquem són grups d'alumnes amb qualificacions semblants, utilitzarem la tècnica de *K-means*. Aquesta tècnica és capaç d'agrupar alumnes en relació a la distància de les seves notes. *K-means* té una limitació, necessita com argument el número de clusters que volem trobar. Hem de buscar una forma de poder trobar la millor  $k$ .

La primera opció és aplicar *K-means* amb diferents  $k$  i per cada prova, calcular la mesura de *Silhouette*. Es calcula la *silhouette* perquè volem saber com de disgregats està cada perfil i determinar si els perfils són robustos. L'algoritme de *K-means* rep com a paràmetre una matriu com la matriu  $C$  amb els alumnes que hagin cursat totes les assignatures de primer de cada grau implantat en la Facultat de Matemàtiques de la Universitat de Barcelona.




Figura 8: Càlcul de la mesura *Silhouette*

buscar:  
'técnica'  
i  
'Però  
clar'  
-¿  
'tan-  
ma-  
teix'  
i  
'pk'

possar  
cre-  
ue-  
tes  
al  
gràfic  
de  
sota

Els gràfics de la Figura 8 ens diuen que la millor  $k$  en ambdós casos és  $k = 2$  i la mesura de silhouette descendeix conforme augmenta el paràmetre  $k$ . Tanmateix, aquest resultat amb  $k = 2$  no és interessant per al nostre anàlisi perquè busquem un número de clusters major que 2, encara que els clusters siguin menys disgregats. Podem opinar que la mesura *silhouette* és major amb  $k = 2$  perquè les notes es separen molt bé en aprovats i en suspesos, sobretot al primer curs de cada grau. Però nosaltres volem explorar més perfils, per tant hem de buscar una altre forma per determinar quina és la millor  $k$ .

L'altre solució proposada és reduir la dimensionalitat de les dades per tal de poder visualitzar-les en un pla dos-dimensional. D'aquesta manera podrem veure visualment els grups que tenim per cada curs. Apliquem la tècnica de PCA per reduir de 10 dimensions a 2. Com a suport visual, podem aplicar un algoritme de clusterització, així com *Mean Shift*, per tal de diferenciar millor els perfils.

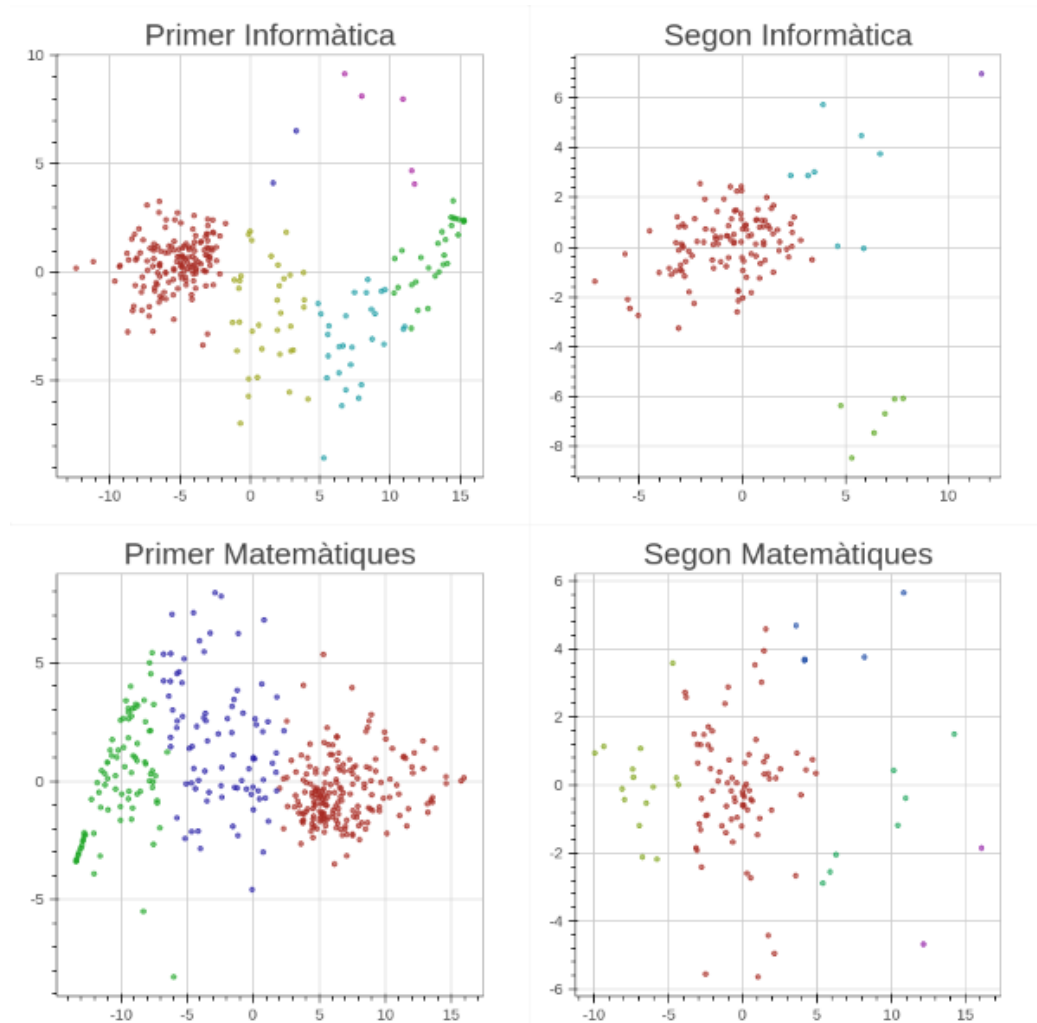


Figura 9: Visualització dels alumnes en un espai dos-dimensional

Com es pot veure a la Figura 9, tenim diferents perfils per cada gràfica. Passem a discutir quina és la millor  $k$  per cada curs.

**Primer d'Enginyeria Informàtica** Ens separa tot el conjunt de punts en 6 agrupacions (*vermell, beix, blau claret, verd, lila i blau fosc*), però el grup *blau fosc i lila* són un grup tan reduït i separat de la resta que el podríem comptar com un sol cluster:  $k = 5$

**Segon d'Enginyeria Informàtica** Per a aquest curs ens separa als estudiants en 4 grups, i podem veure que els clusters estan força disgregats entre ells i no fa falta unificar cap:  $k = 4$

**Primer de Matemàtiques** Per a primer del grau de Matemàtiques ens separa les observacions en 3 clusters. Com no es veu cap anomalia, a part de la petita separació dels petits punts verds, podem considerar els tres clusters:  $k = 3$

**Segon de Matemàtiques** Aquest és el curs que m'ha donat més problemes, perquè té els punts més distanciats entre ells i això fa que no es pugui interpretar el número de clusters per aplicar *K-means*. Més endavant veurem que el número de clusters òptim és 3, ja que amb 4 ens dóna dos clusters molt semblants, els quals es poden unificar:  $k = 3$

Ara que ja tenim el valor de  $k$  adequat per cada curs, podem aplicar la tècnica de *K-means*. S'ha utilitzat una combinació de colors adequada per cada perfil, veure Figura 10




Figura 10: Categoria de colors utilitzada per representar els perfils d'estudiants

Comentem els resultats obtinguts amb el curs de primer d'Enginyeria Informàtica on hem aplicat *K-means* amb  $k = 5$ .




Figura 11: Perfils d'alumnes de primer d'Enginyeria Informàtica




Figura 12: Percentatges de cada agrupació

Cada gràfic de la Figura 11 correspon als diferents perfils d'estudiants que ha trobat la tècnica de *K-means*. En cadascun d'ells trobem com a títol l'etiqueta assignada a aquell perfil i el color de cadascun depèn de la categoria (Figura 10). En l'eix d'abscisses es veuen les assignatures (en aquest cas les de primer d'Enginyeria Informàtica), i en l'eix d'ordenades la mitja

Possar  
la  
eti-  
que-  
ta  
del  
per-  
fil en  
la  
lle-  
gen-  
da  
si es  
pot

de les notes dels alumnes de cada assignatura (longitud de la barra). Per últim les línees negres determinen la desviació estàndard de la distribució de cada assignatura i la línea vermella és una marca per identificar l'alçada de l'aprobat. En la Figura 12 es mostra el percentatge d'alumnes que pertanyen a cada agrupació.

Els perfils explorats del primer curs d'Enginyeria Informàtica es descriuen de la següent manera:

**1 - BN1: Bones notes de primer d'Informàtica** Aquest perfil correspon als alumnes que tenen bones notes en totes les assignatures de primer i com podem veure en el gràfic de pastilla, representen un 23.37% del total, sent el segon perfil més abundant. Podem veure ara que la mostra és més gran, la desviació estàndard és menor, és a dir, aquest perfil és força estable, tots els estudiants que hi pertanyent es distancien amb una qualificació promig d'1.5 aproximadament.

**2 - S1: Suspesos de primer d'Informàtica** Com podem veure, aquest perfil són els estudiants que suspenen la majoria d'assignatures. A primeres podem pensar que són els que solen deixar la carrera i és això el que anem a respondre en la següent pregunta plantejada. També podem veure que són un 17.2 % del total d'alumnes que han cursat les assignatures de primer, no són un percentatge baix.

**3 - A1: Aprovats de primer d'Informàtica** Són la major part dels alumnes, amb un 38.31% del total, i són els alumnes que de mitja treuen entre 5 i 7. Igual que passa amb el cluster *BN1*, la desviació estàndard de cada assignatura és força baixa, i això fa que el cluster sigui consistent.

**4 - MP1: Millors en programació de primer d'Informàtica** Aquest perfil encaixa amb els alumnes que tenen millors notes en les assignatures de programació que en les de Matemàtiques. La distribució d'aquest és molt dispersa, això ho podem veure per la llargada de la barra negra (desviació estàndard). També és, perquè la mostra és petita, representa el 5.36% de la mostra total.

**5 - MM1: Millors en Matemàtiques de primer d'Informàtica** Aquest perfil igual que *MP1*, és bastant inestable, ja que tenen una desviació estàndard alta, és a dir, hi ha una diversitat de notes elavada, no es concentren tots els alumnes a tenir la mateixa nota. Tot i que siguin dispersos, són un 15.71 %

del total, un percentatge forç alt.

Si mirem el resultats en general de les gràfiques de la Figura 11, podem veure que en l'assignatura *Estructura de Dades* (ED) presenta sempre una desviació més petita que la resta d'assignatures en cada perfil, és a dir, que les notes es concentren més en la mitja marcada. També es veu en tots els perfil, sense mirar la qualificació corresponent, la nota més alta correspon a l'assignatura de *Càlcul* (CAL).

Seguint amb l'anàlisi, a la Figura 13 podem veure els perfils de tots els alumnes que hagin cursat totes les assignatures de segon. S'ha aplicat *K-means* amb  $k = 4$ .

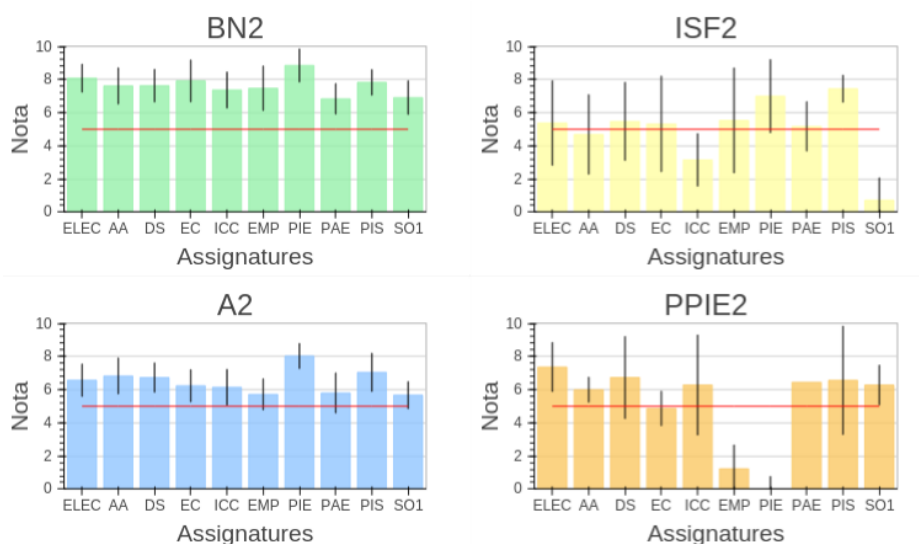


Figura 13: Perfils d'alumnes de segon d'Enginyeria Informàtica

Els perfils explorats del segon curs d'Enginyeria Informàtica es descriuen de la següent manera:

**1 - BN2: Bones notes de segon d'Informàtica** Aquest és un perfil força semblant a *BN1*, és per això que ens plantejem, a la secció 5.4, la pregunta: *Amb quin perfil de provinença encaixa cadascun d'aquests perfils?* És cert que els que tenen bones notes a primer, solen ser els que treuen bones notes a segon? Això ho anomenem conservació de clusters. De tots els alumnes que han cursat segon un 28.68% pertanyen a aquest cluster, més d'un quart de la mostra.






Figura 14: Percentatges de cada agrupació

**2 - A2: Aprovats de segon d'Informàtica** Aquest perfil és semblant al perfil *A1*, pertany als alumnes que tenen notes entre 5 i 7 en totes les assignatures. Són el 60.47% del total d'alumnes que han cursat les assignatures de segon.

**3 - ISF2: ICC i SO1 fluixes** Aquest perfil encara que sigui minoritari, amb un 6.2% del total, és força curiós, ja que són alumnes que tenen *Introducció a la Computació Científica* (ICC) i *Sistemes operatius I* (SO1) amb notes més baixes que la resta. S'ha de dir que tot i que les mitjes siguin més petites, les desviacions estàndards són molt altes, el que fa que les notes dels alumnes siguin més diverses i no segueixin exactament la distribució de mitjes del perfil.

**4 - PPIE2: Problemes amb PIE i Empresa** Aquest és el perfil amb un percentatge més petit de població, un 4.65%. És un perfil força dispers, ja que les desviacions estàndard són altes, i això es pot veure en assignatures com PIS o ICC. A més és curiós perquè és un grup que apareix amb *Empresa* (EMP) i *Probabilitat i estadística* (PIE) suspeses.

Ens podem fixar que la distribució de mitjes del perfil *BN2* i *A2*, és força semblant, només que *BN2* té les mitjes més altes.

Deixant enrere al grau d'Enginyeria Informàtica, passem a analitzar els estudiants del grau en Matemàtiques. Comencem amb els alumnes de primer, els quals els segmentem en 3 agrupacions ( $k = 3$ ).

En la figura 15 i reffig:pasprimermates, presentem els perfils i els percentatges de les agrupacions, respectivament.




Figura 15: Perfils d'alumnes de primer de Matemàtiques




Figura 16: Percentatges de cada agrupació

Els perfils explorats de primer curs de Matemàtiques es descriuen de la següent manera:

**1 - A1: Aprovats de primer de Matemàtiques** Aquest perfil pertany als estudiants que tenen totes les assignatures aprovades de mitja i són els que formen la major part del total, amb un 50.13%.

**2 - S1: Suspesos de primer de Matemàtiques** Per últim, i sense faltar, tenim els alumnes que de mitja suspenen totes les assignatures. Conformen un 27.51% del total d'estudiants.

**3 - NE1: No estables de primer de Matemàtiques** Podem veure que aquest cluster té les mostres molt distanciades, per les desviacions estàndards que presenta. Aquest perfil l'he classificat com *No estables de primer*, ja que són alumnes que amb prou feines poden aprovar certes assignatures. Conformen un 22.37% del total d'alumnes.

Per últim s'observa als alumnes de segon de Matemàtiques a la Figura 17 i reffig:passegonmates.

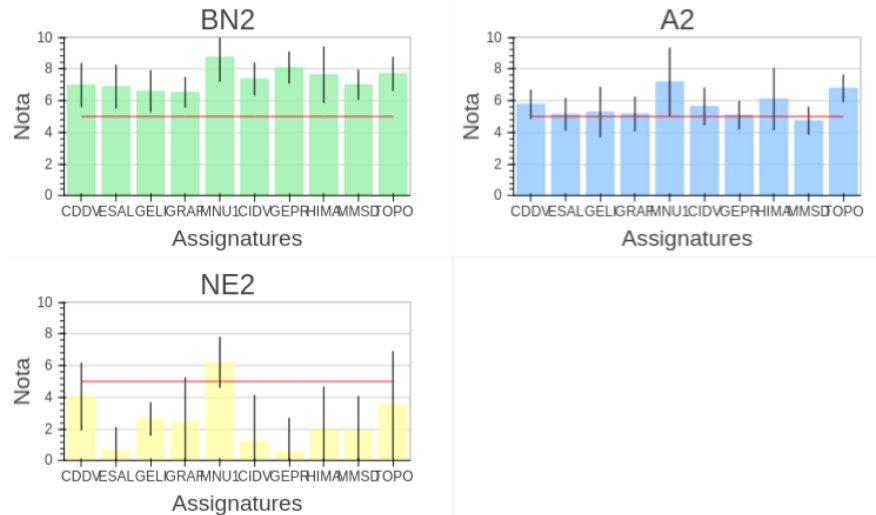


Figura 17: Perfils d'alumnes de segon de Matemàtiques




Figura 18: Percentatges de cada agrupació

Els perfils explorats de segon curs de Matemàtiques es descriuen de la següent manera:

**1 - BN2: Bones notes de segon de Matemàtiques** Torna a aparèixer aquest tipus de perfils corresponent a alumnes amb mitjes de qualificacions altes. Tot i així, el percentatge d'alumnes que pertanyen a aquest cluster és elevat, un 34.86%. Aquest fet fa pensar que totes les assignatures suposen la mateixa dificultat per aquests alumnes.

**2 - A2: Aprovats de segon de Matemàtiques** Novament tenim als alumnes amb qualificacions en el rang d'aprobat, tot i que la majoria freguen la línia de l'aprobat. Com és en tots els cursos, aquest és el perfil més abundant, amb un 57.80%.

**3 - NE2: No estables de segon de Matemàtiques** Igual que a primer del grau de Matemàtiques tenim el perfil de *No estables*, aquí el tornem a tenir, tot i que aquest perfil només té aprovada per mitja una assignatura, *Mètodes numèrics I* (MNU1). Pertanyen al 7.34% del total.

En aquest curs tenim un efecte semblant a primer d'Enginyeria Informàtica amb l'assignatura de *Càlcul*, hi ha una assignatura que en tots els perfils correspon a la mitja més alta, *Mètodes numèrics I* (MNU1).

Arran d'aquests resultats, el tutor d'estudis pot aplicar l'acció de reforçar l'aprenentatge i el seguiment de tots aquells alumnes que s'agrupen en perfils on la majoria d'assignatures no passin de la línia vermella de l'aprobat.

buscar:  
'tu-  
tor  
d'es-  
tudi'

### 5.3 Tassa d'abandonament per perfil

La primera pregunta que ens plantegem és: *Quina és la tassa d'abandonament per cada tipus de perfil?* És cert que els que suspenen abandonen la carrera? Ara ho podrem demostrar amb gràfics estadístics. Ens centrarem en la tassa d'abandonament dels alumnes que cursen primer, tant d'Enginyeria Informàtica com el grau de Matemàtiques. Mostrarem els perfils, figura 19, per poder discutir cada perfil amb la seva tassa d'abandonament, mostrada a la figura 20.




Figura 19: Perfils d'alumnes de primer d'Enginyeria Informàtica




Figura 20: Tassa d'abandonaments per perfil de primer d'Enginyeria Informàtica

Els alumnes que amb més probabilitat deixen la carrera són els que suspenen (S1), seguits d'estudiants que no tenen unes notes massa estables (MP1 i MM1). És a dir, que la majoria que passen a segon pertanyen al cluster BN1 i A1. Però si ens fixem una mica en el gràfic d'abandonaments, els perfils d'aprovat (A1) i de bones notes (BN1), hi ha un petit percentatge indicat

que diu que abandonen la carrera. En les dades que tenim, no tenim un camp que ens indiqui si un alumne ha abandonat la carrera o no, ja que no ho tenen registrat. Hem hagut d'agafar per cada perfil tot el conjunt d'alumnes d'aquell perfil i s'ha comprovat per cadascún si té assignatures matriculades a l'any següent. Però clar, hi han alumnes del darrer any que s'han de matricular per l'any vinent encara (i no apareixen matriculats a l'any següent), per això hi ha un petit marge d'error i els clusters *BN1* i *A1* apareixen amb una mínima taxa d'abandonaments degut a aquest error.

Per altra banda, tenim el curs de primer de Matemàtiques, on apliquem el mateix algoritme explicat en el paràgraf anterior. També trovem un petit marge d'error en els perfils que ho aproven tot.

buscar  
tots  
els  
"Per  
altra  
ban-  
daï pos-  
sar  
, ,  
,

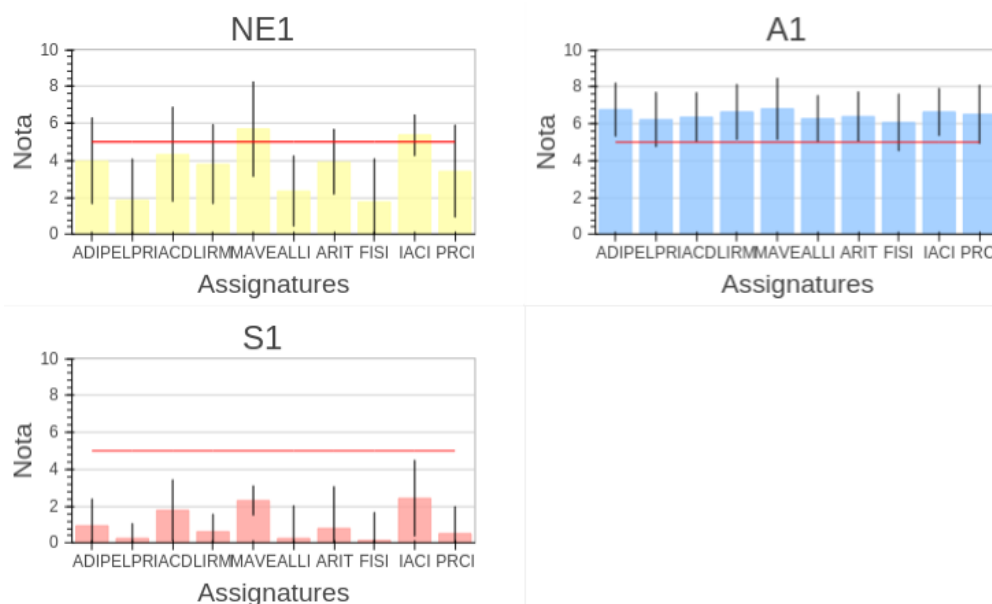


Figura 21: Perfils d'alumnes de primer de Matemàtiques

A la figura 22 presentem la taxa d'abandonament dels alumnes de primer del grau de Matemàtiques. Igual que en Enginyeria Informàtica, ens trobem que la major taxa d'abandonament es troba en els alumnes que suspelen per mitja totes les assignatures (S1). Seguidament els hi segueixen els estudiants que no tenen unes notes massa regulars i com s'ha comentat anteriorment, els alumnes que estan classificats com *Aprovats*, també surten amb una taxa mínima d'abandonament.

Tant al grau d'Enginyeria Informàtica com al grau de Matemàtiques podríem definir una acció per al tutor. Després del primer curs, podem incidir (enviar




Figura 22: Tassa d'abandonaments per perfil de primer de Matemàtiques

correus electrònics, aconsellar) als alumnes dels perfils amb baixes notes com són els grups S1, MM1 i MP1 per al grau d'Enginyeria Informàtica i S1 i NE1 per al grau de Matemàtiques.

## 5.4 Conservació de clusters

La pregunta que ens plantejem és: *Amb quin perfil de provinença encaixa cadascun d'aquests perfils?* El que es vol mirar en aquesta pregunta és la conservació de clusters, per exemple, els estudiants que treuen bones notes a primer, segueixen treien bones notes a segon? O, de quina via d'accés solen provenir els estudiants de primer de Matemàtiques? Preguntes com aquestes anem a resoldre en aquest apartat.

Començarem, com hem fet anteriorment, amb els estudiants que han cursat primer d'Enginyeria Informàtica. Com s'ha explicat en la secció de preguntes plantejades, contrastem primer d'Enginyeria Informàtica amb les vies d'accés: Batxillerat i salt d'Universitat.

En la figura [23] podem veure que a l'interior del cercle, tenim el mateix gràfic de pastilla que s'ha vist anteriorment dels perfils dels estudiants de primer d'Enginyeria Informàtica [fig: 12]. Per fóra del cercle de cada perfil es veu quantitativament d'on venen els alumnes del perfil.

Es pot veure com en tots els perfils, venen meitat de Batxillerat i meitat de Salt d'Universitat aproximadament. Es pot distingir que els estudiants classificats com *Suspesos* solen venir més de Batxillerat que no pas d'una altre Universitat, tot i que la diferència és petita. Com s'ha vist en la gràfica d'abandonament [fig: 20], els alumnes que passen amb més abundància a segon són els classificats com *A1* i *BN1*, per tant procedim a eliminar a la resta, ja que són minoria, i queda més llegible en la figura 24.

Ara és veu amb més claredat el significat d'un gràfic com aquest, ja que




Figura 23: Conservació de clusters dels alumnes de primer d'Informàtica

podem veure com els que solen treure bones notes a primer d'Enginyeria Informàtica, solen treure bones notes a segon també, i els que es classificaven com *Aprovats de primer*, solen parar a *Aprovats de segon*. També podem veure com un petit percentatge d'alumnes que treuen notes a primer, passen a treure notes més baixes a segon, igual que alumnes etiquetats com *Aprovats de primer* amb una petit quantitat paren a perfils inestables com *ISF2* o *PPIE2*.






Figura 24: Conservació de clusters dels alumnes de segon d'Informàtica

Per últim es veurà la provinença dels estudiants de primer del grau de Matemàtiques, on també es pot veure una tendència [fig: 25].

En la gràfica de la figura 25 es veu amb claredat que la major part d'estudiants que han cursat primer del grau de Matemàtiques, venen de Batxillerat.

Una de les raons per les quals vam plantejar aquesta pregunta, era per saber si podem determinar un perfil d'estudiant al grau a partir de la via d'accés d'aquest. Malauradament no s'ha trobat cap correlació com aquesta, però s'han pogut veure resultats molt coherents i que no esperavem trobar. L'anàlisi de les dades ens ha permès extreure informació útil per als tutors d'estudis. Depenent del perfil actual de l'alumne se li podrà recomanar un material de suport a l'estudi adicional.




Figura 25: Conservació de clusters dels alumnes de primer de Matemàtiques

## 5.5 Predicció de notes i ranking de dificultat d'assignatures

En aquest apartat s'expliquen les tècniques de predicció que hem fet servir i quins resultats, tant quantitatius com qualitatis, s'han obtingut. El que busquem és poder mostrar un ranking, personalitzat per cada alumne, d'assignatures ordenades per la dificultat (és a dir, per notes) que li costarà a cada estudiant.

Abans de construir el ranking, necessitem saber quina és la tècnica de predicció que s'ajusta millor a les nostres dades. Les tècniques utilitzades per aquest experiment han sigut les següents, anteriorment explicades [secció: 4.2.2]:

- Recomanador col·laboratiu bassat en estudiant (RCxE)
- Recomanador col·laboratiu bassat en assignatures (RCxA)
- *Random Forest Regressor* (RFR)
- Regressor lineal (LR)

Anem a mesurar quantitativament quin dels 4 predictors s'adequa més a les nostres dades. Les mètriques que s'utilitzaran són les que ja s'han explicat en la secció de *Mètriques de predictors* [secció: 4.2.2.4].

### 5.5.1 Estratègia de validació

Totes les proves realitzades s'han fet a partir de les notes d'Enginyeria Informàtica. Per fer aquestes proves s'ha utilitzat la tècnica de *cross-validation*, que consisteix en la partició del conjunt de les dades en *training* i *test* de tal manera que s'entrena amb el subconjunt de *training* i s'avalua amb el subconjunt de *test*. Fent aquestes proves podrem comprovar quin dels predictors és el més adequat. Les proves s'han realitzat a partir de dos conjunts diferents de dades:

- Una on s'aplica com a *training* les notes de primer d'Enginyeria Informàtica i com a *test* les notes de segon. A partir d'ara l'anomenarem conjunt n°1.
- Per un altre banda s'ha aplicat un *training* amb les notes de primer i segon, i un *test* amb les notes de tercer d'Enginyeria Informàtica. A partir d'ara l'anomenarem conjunt n°2.

Per cadascun dels conjunts s'han realitzat diferents proves, detallades a continuació:

#### 5.5.1.1 Proves amb dades continues

Provem els predictors mirant l'error produït amb les notes real i les predites qualificades del 0 al 10. Les mesures utilitzades en aquesta prova són:

- **Error Promig Absolut** Per calcular la diferència mitja d'error produït.
- **Error Promig Quadràtic** Per veure si els errors són molt elevats.
- **Coefficient de Pearson** Per veure si la distribució entre les notes es manté.
- **Desviació estàndard** Utilitzada per veure si els errors es concentren o estan molt disgregats.

A més a partir dels errors produïts per cada predictor, es mostra un diagrama de caixes [25] per representar la distribució dels errors. Més endavant amb un dels resultats s'explicarà l'interpretació del diagrama de caixes. S'utilitza un 90% de *training* i un 10% de *test*.

### 5.5.1.2 Proves amb dades discretes

Igual que comprovem l'error produir amb valors continus, del 0 al 10, ara etiquetem les notes segons el seu rang. El rang que s'ha utilitzat és el següent:

- **Suspés** Notes inferiors a 5 ( $nota < 5$ )
- **Aprovat** Notes entre 5 i 7 ( $5 \leq nota < 7$ )
- **Notable** Notes entre 7 i 9 ( $7 \leq nota < 9$ )
- **Excel·lent** Notes superiors a 9 ( $nota \geq 9$ )

Per poder visualitzar aquesta prova s'ha utilitzat una matriu de confusió [26], on es representa amb un mapa de color (o heatmap). En la següent secció s'explicarà que és un mapa de color juntament amb els resultats obtinguts. S'utilitza un 50% de *training* i un 50% de *test*.

### 5.5.1.3 Proves amb ranking d'assignatures

Per últim tenim les proves realitzades per mesurar el ranking que volem desenvolupar. La mètrica utilitzada ha sigut la *Mean Ranking Score*, que com ja s'ha explicat anteriorment [secció: 4.2.2.4], és una mètrica que ens permet mesurar quant de bó és un ranking. S'utilitza un 90% de *training* i un 10% de *test*.

## 5.5.2 Resultats de les proves amb dades continues

Comançarem amb les proves fetes amb dades continues amb els dos conjunt de dades que s'han explicat en l'apartat anterior.

En la figura 26 podem veure un diagrama de caixes de l'error de predicció dels diferents predictors. Aquest tipus de diagrama representa visualment una distribució. Cada caixa té les mateixes característiques: la línia del centre representa la mediana de la distribució, la caixa visualitza un 50% de la mostra (des del primer quartil, fins al tercer), les línies verticals determinen el límit de les distribucions i per últim tota mostra que estigui fóra de lo normal (mostra atípica) es visualitza per fóra dels límits amb un punt.

La distribució que podem veure a la figura 26 són els errors que es presenten en cada predicció, pertant un predictor perfecte, mostrarà una distribució uniforme en el 0. En la figura es pot veure els quatre predictors utilitzats i




Figura 26: Prova amb dades contínues del conjunt n°1

quina distribució d'error segueix cadascún. Veiem que el predictor més estable i que concentra millor els errors són el recomanador col·laboratiu basat en estudiant (RCxE) i el *random forest regressor* (RFR). Per un altra banda, tenim el regressor lineal que presenta la mediana més baixa, tot i que el tercer quartil és massa elevat. Els *outliers* (mostres atípiques) que veiem tenen una explicació. Què passa si un alumne té un imprevist i no pot cursar una assignatura ja matriculada? Aquest factor no el contempen els predictors. És per això que tenim observacions atípiques, perquè els predictors potser prediuen que un alumne treurà un 7, però l'alumne per qualsevol raó es desmatricula de l'assignatura, llavors en aquella assignatura li queda un 0. En la taula 11 es mostra un exemple d'una mostra atípica amb una prova qualitativa. Les mateixes conclusions podem extreure de les mètriques que utilitzem per fer aquesta prova:

<i>Algoritme \ Mètriques</i>	MAE	MSE	PCC	std
<b>RCxE</b>	0.796	0.910	0.578	0.526
<b>RCxA</b>	1.006	1.509	0.309	0.705
<b>RFR</b>	0.868	1.152	0.505	0.632
<b>LR</b>	0.809	1.071	0.575	0.646

Taula 4: Mètriques per a proves quantitatives amb dades contínues del conjunt n°1

Observem amb les mètriques que els millors predictors són RCxE, RFR i LR, tot que el presenta menys errors és RCxE ja que té el l'error promig

quadràtic més baix.

Igual que hem fet proves amb el conjunt n°1, procedim a visualitzar en la figura 27 i a la taula 5 les proves amb el conjunt n°2.




Figura 27: Prova amb dades continues del conjunt n°2

<i>Algoritme \ Mètriques</i>	MAE	MSE	PCC	std
<b>RCxE</b>	0.869	1.590	0.276	0.914
<b>RCxA</b>	0.906	1.781	0.141	0.980
<b>RFR</b>	0.786	1.522	0.339	0.951
<b>LR</b>	0.932	1.890	0.283	1.011

Taula 5: Mètriques per a proves quantitatives amb dades continues del conjunt n°2

En la figura 27 s'observa com els millors predictors són el RCxE i el RFR, tot i que ara ambdós presenten més mostres atípiques. Les distribucions i els resultats són semblants als resultats provats amb les dades anteriors. L'únic predictor que marca més diferència és el Random Forest Regressor, ja que disminueix força la mediana de la distribució, i l'error promig absolut.

### 5.5.3 Resultats de les proves amb dades discretes

Ara passem a veure els resultats que s'han obtingut amb les notes discretes (suspès, aprovat, notable i excel·lent). Com ja s'ha explicat, la representació d'aquestes proves es fa amb una matriu de confusió, seguidament passo a descriure que representa.




Figura 29: Matriu de confusió del conjunt n°1

En cada matriu de colors de la figura 29 podem veure 16 caselles, cada fila i columna posa: S, A, N i E, que significa: suspès, aprovat, notable i excel·lent. Cada cel·la significa el percentatge de vegades que la qualificació predita coincideix amb la qualificació real corresponent. Possem un exemple, per acabar d'entendre, en la primera figura apareix en la correspondència de aprovats amb aprovats un 40.26%, això significa que el 40.26% de les proves diu el

predictor que un alumne treurà una nota d'aprobat i la nota real és aprovat. Si ens fixem com més alt sigui el percentatge, més fosca és la casella. Per tant el que busquem és tenir fosca la diagonal, ja que vol dir que ha encertat tot. Ho representem amb aquest tipus de representació perquè equivocar-se de suspès a aprovat és acceptable, però no de suspès a excel·lent, és per això que s'ha de veure una tendència de color a les rodalies de la diagonal.

Podem veure que els millors predictors són els recomanadors, ja que mantenen força alta la intensitat de color de la diagonal i el color fosc es manté força concentrat a la diagonal. Si ens fixem en el *Random Forest Regressor* i en el *Regressor lineal* confon més per les seves rodalies. En canvi trobem que tots els predictos confonen aprovats per excel·lents.

Ara procedim a fer les proves amb el conjunt n°2. Els resultats són els presentats a la figura 31.




Figura 31: Matriu de convulsió. Training: primer i segon



En la figura 31 es pot veure com RCxE, RCxA i RFR tenen resultats semblants, però en canvi veiem que el regressor lineal es dispersa molt i sol fer fallos amb un salt de dos categories, com per exemple confondre notables amb suspesos. Tot i així, tots ells concentren força bé els resultats a la diagonal.

#### 5.5.4 Resultats de les proves amb ranking d'assignatures

Per finalitzar la part de proves quantitatives, fem les proves per al ranking d'assignatures. Per això s'ha utilitzat, com ja s'ha explicat, la mesura de *Mean Ranking Score* per avaluar la qualitat de cada predictor i veure quin predictor és més bo per fer un ranking. Els resultats obtinguts són purament numèrics i venen representats en la següent taula:

	RCxE	RCxA	RFR	LR
MRS	2.05	2.975	2.2	1.975

Taula 6: Mean Ranking Score. Training: primer

	RCxE	RCxA	RFR	LR
MRS	2.375	3.4	2.375	2.525

Taula 7: Mean Ranking Score. Training: primer i segon

En les taules 6 i 7 es poden veure els resultats de les dues proves (amb diferents *training*) juntes per poder-les discutir. Recordem que la mesura MRS és una mesura que com més propera a 0, millor. Si ens fixem els valors són més baixos a la primera taula, i el millor predictor per aquesta és el recomanador col·laboratiu basat en l'estudiant. Amb el conjunt n°2 podem veure que els millors predictors són RCxE i RFR.

Podem concloure que el predictors més adequat per a les nostres dades són el RCxE i el RFR, tot i que el RCxE dona resultats més positius. Ara procedim a fer les proves qualitatives amb el conjunt n°1 amb el RCxE, és a dir, entrenem el recomanador amb les notes de primer i avaluem amb les notes de segon.

### 5.5.5 Proves qualitatives

En aquest apartat mostra un cas d'èxit i un de fracàs per fer una recomanació de notes, i seguidament un cas d'èxit i un de fracàs del ranking d'assignatures.

En les proves quantitatives, hem pogut veure que el millor predictor per predir notes quantitatives (de 0 a 10) és el recomanador col·laboratiu basat en l'estudiant (RCxE). És per això que utilitzarem aquest predictor per fer les proves qualitatives.

#### 5.5.5.1 Resultats de les proves amb dades continues

Primer procedirem a mostrar un dos casos amb dades continues, és a dir, agafarem les notes de primer d'Enginyeria Informàtica de dos alumnes i discutirem els resultats de la predicció amb les notes reals de l'alumne.

	P1	DDB	IO	ALGE	CAL	MD	FIS	ALGO	P2	ED
Notes	7.40	8.00	6.80	6.80	6.80	7.90	6.80	7.60	7.30	9.00

Taula 8: Cas d'èxit: Notes reals d'un alumne primer

	Notes reals	Notes predites
ELEC	8.80	7.29
AA	7.50	7.44
DS	7.00	6.80
EC	6.00	6.00
ICC	6.60	6.74
EMP	7.20	7.64
PIE	8.00	6.63
PAE	7.50	7.23
PIS	9.00	8.81
SO1	6.80	6.31

Taula 9: Cas d'èxit: Resultats de la predicció

En la taula 8 es poden veure les notes reals que ha tret l'alumne en primer, i en la taula 9 les notes que ha tret en segon juntament amb les notes predites pel predictor. Les mètriques d'aquesta predicció són:

- **MAE** 0.47
- **MSE** 0.48

Si mirem detingudament la comparació de les notes podem veure que la diferència és baixa, l'assignatura que manté una major distància és *Probabilitat i Estadística* (PIE).

	P1	DDB	IO	ALGE	CAL	MD	FIS	ALGO	P2	ED
Notes	6.00	8.40	6.00	6.50	7.10	7.10	5.50	7.00	6.00	6.00

Taula 10: Cas de fracàs: Notes reals d'un alumne de primer

	Notes reals	Notes predites
ELEC	7.10	7.45
AA	5.10	6.06
DS	0.00	5.63
EC	6.30	6.02
ICC	5.30	6.38
EMP	6.40	7.38
PIE	7.30	6.60
PAE	8.30	7.51
PIS	0.00	6.89
SO1	7.60	5.85

Taula 11: Cas de fracàs: Resultats de la predicció

En les taules 10 i 11 podem veure un cas de fracàs, on les mètriques han donat el següent resultat:

- **MAE** 1.94
- **MSE** 8.66

Aquesta és una de les mostres atípiques que s'havien vist en els diagrames de caixa. Podem veure que realment el predictor ha encertat amb la majoria d'assignatures, llevat de PIS i DS. Resulta que l'alumne té un 0 en ambdues assignatures, això pot ser per un error o per que l'alumne hagi abandonat l'assignatura, entre altres. És per això que el predictor no pot contemplar casos com aquest i per això presenta *outliers*. En aquest cas a més podem veure com l'error promig absolut no és massa alt, però l'error promig quadràtic és elevat a conseqüència de les assignatures de *Projecte integrat de Software* (PIS) i *Disseny de Software* (DS).

#### 5.5.5.2 Resultats de les proves amb ranking d'assignatures

En aquest apartat es veuen dos casos del ranking d'assignatures, un d'èxit i l'altre de fracàs. Comencem amb el cas d'èxit presentat a les taules 12 i 13.

	P1	DDB	IO	ALGE	CAL	MD	FIS	ALGO	P2	ED
Notes	6.00	6.30	6.00	6.00	6.50	6.00	5.50	6.80	6.00	6.00

Taula 12: Notes reals de primer del segon cas d'èxit

	Notes reals	Notes predites
1	PAE	PAE
2	PIE	ELEC
3	EMP	EMP
4	ELEC	PIE
5	ICC	AA
6	EC	ICC
7	AA	EC
8	SO1	PIS
9	PIS	SO1
10	DS	DS

Taula 13: Resultat de predicció del segon cas d'èxit

Per determinar el millor i el pitjor cas hem hagut d'escollir els alumnes que tenien millor i pitjor mesura de *Mean Ranking Score*. En la taula 12, com els altres casos, veiem les notes que ha tret l'alumne en les assignatures de primer, però ara en la taula 13 podem veure el ranking d'assignatures

ordenades per dificultat. En aquest cas s'aprecia com el ranking predit és semblant al ranking real. La *Mean Ranking Score* dona 1.

	P1	DDB	IO	ALGE	CAL	MD	FIS	ALGO	P2	ED
Notes	8.80	5.80	6.60	7.30	8.50	8.00	5.30	6.50	9.20	7.40

Taula 14: Notes reals de primer del segon cas de fracàs

	Notes reals	Notes predites
1	ICC	PIS
2	PIE	PIE
3	PAE	EMP
4	DS	AA
5	ELEC	PAE
6	SO1	ELEC
7	EMP	SO1
8	PIS	EC
9	AA	DS
10	EC	ICC

Taula 15: Resultat de predicció del segon cas de fracàs

Per últim podem veure aquest cas de fracàs en les taules 14 i 15, on els dos ranking no s'assemblen. La seva *Mean Ranking Score* ens ha donat 3.8, una MRS alta i recordem que la MRS és la mitja d'error de diferència de posicions del ranking.

Amb els resultats que hem arribat en aquest apartat de predicció pot ser útil per al tutor d'estudis. Pot determinar quines assignatures anirà malament un alumne i així aplicar una acció corresponent, com ara recomanar suport adicional o repàs de les matèries relacionades amb l'assignatura en qüestió.

## 6 Conclusions

Per dur a terme aquest treball era necessari seguir les etapes d'un projecte de ciència de les dades. Hem pogut transformar les dades en coneixement, que era un dels objectius plantejats en aquest treball de fi de grau. Fer un anàlisi estadístic sobre dades acadèmiques ens serveix com a base per al projecte d'innovació docent.

Com resultat de la investigació dins del marc del projecte d'innovació docent, és possible concloure resultats com l'alta conservació de perfils quan un estudiant passa de primer a segon d'Enginyeria Informàtica, o una alta taxa d'abandonament per part d'alumnes que suspenden les assignatures de primer. A més, tot i que en alguns resultats no s'ha obtingut el que s'esperava, s'han explorat nous resultats i conclusions que no s'havien arribat a tenir en compte.

Amb els resultats obtinguts, aquest treball pot ajudar a prendre decisions al cap d'estudis, tutors i professors dels estudis de la Facultat de Matemàtiques.

### 6.1 Treball futur

Com s'ha explicat des del principi, aquest treball entra dins del marc d'un projecte d'innovació docent, i forma part de l'anàlisi estadístic de les dades acadèmiques. El treball futur a implementar en aquest projecte són els següents punts:

**Desenvolupament d'un sistema intel·ligent** Construcció d'una eina de suport per al tutor d'estudis que li permeti explorar amb més profunditat les dades acadèmiques d'un alumne o d'una assignatura. Una de les eines a incorporar seria un sistema de visualització de les recomanacions de matrícula i gràfics estadístics que puguin ajudar a visualitzar la informació que presenten les dades.

**Avaluació** Un cop construïda l'eina per al tutor, hauria de passar a fase de prova, per a que els tutors d'estudis la provin i puguin identificar problemes o limitacions del sistema.

## Referències

- [1] “Presentació del projecte d’innovació docent” [Online].  
Disponible: <http://mid.ub.edu/webpmid/content/sistema-intel%E2%80%A2ligent-de-suport-al-tutor-d%E2%80%99estudis>
- [2] Normalització d’unitat tipificada - Wikipedia [Online].  
Disponible: [https://en.wikipedia.org/wiki/Standard\\_score](https://en.wikipedia.org/wiki/Standard_score)
- [3] Plana web de Github [Online].  
Disponible: <https://github.com>
- [4] Plana web de Bitbucket [Online].  
Disponible: <https://bitbucket.org>
- [5] Plana web de la plataforma Trello [Online].  
Disponible: <https://trello.com>
- [6] Llenguatge de programació Python [Online].  
Disponible: <https://www.python.org>
- [7] Biblioteca informàtica de Python: Pandas [Online].  
Disponible <http://pandas.pydata.org>
- [8] Biblioteca informàtica de Python: Numpy [Online].  
Disponible: <http://www.numpy.org>
- [9] Biblioteca informàtica de Python: Scikit-learn [Online].  
Disponible: <http://scikit-learn.org>
- [10] Biblioteca informàtica de Python: Bokeh [Online].  
Disponible: <http://bokeh.pydata.org>
- [11] Biblioteca informàtica de Python: Seaborn [Online].  
Disponible: <http://stanford.edu/~mwaskom/software/seaborn>
- [12] Entorn de programació de Python: Ipython Notebook [Online].  
Disponible: <http://ipython.org/notebook.html>



- [13] Editor de L<sup>A</sup>T<sub>E</sub>X[Online].  
Disponible: <http://www.xmlmath.net/texmaker>
- [14] K-means d'Scikit-learn [Online].  
Disponible: <http://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>
- [15] Mean Shift d'Scikit-learn [Online].  
Disponible: <http://scikit-learn.org/stable/modules/generated/sklearn.cluster.MeanShift.html>
- [16] Imatge retocada de la plana web d'Scikit-learn [Online].  
Disponible: [http://scikit-learn.org/stable/\\_images/plot\\_cluster\\_comparison\\_001.png](http://scikit-learn.org/stable/_images/plot_cluster_comparison_001.png)
- [17] Mesura *Silhouette* d'Scikit-learn [Online].  
Disponible: [http://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette\\_score.html](http://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html)
- [18] “CART tree titanic survivors” by Stephen Milborrow - Own work. Licensed under CC BY-SA 3.0 via Wikimedia Commons [Online].  
Disponible: [https://commons.wikimedia.org/wiki/File:CART\\_tree\\_titanic\\_survivors.png#/media/File:CART\\_tree\\_titanic\\_survivors.png](https://commons.wikimedia.org/wiki/File:CART_tree_titanic_survivors.png#/media/File:CART_tree_titanic_survivors.png)
- [19] *Random Forest Regressor* d'Scikit-learn [Online].  
Disponible: <http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>
- [20] Regressor lineal d'Scikit-learn [Online].  
Disponible: [http://scikit-learn.org/stable/modules/generated/sklearn.linear\\_model.LinearRegression.html](http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html)
- [21] “Normdist regression” by Amatulic de la Viquipèdia en anglès (same as Anachronist on Wikimedia) - Transferred from en.wikipedia to Commons. Transfer was stated to be made by User:anachronist.. Licensed under Domini públic via Wikimedia Commons  
Disponible: [https://commons.wikimedia.org/wiki/File:Normdist\\_regression.png#/media/File:Normdist\\_regression.png](https://commons.wikimedia.org/wiki/File:Normdist_regression.png#/media/File:Normdist_regression.png)

- [22] Mesura del error promig absolut d'Scikit-learn [Online].  
Disponible: [http://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean\\_absolute\\_error.html](http://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html)
- [23] Mesura del error promig quadràtic d'Scikit-learn [Online].  
Disponible: [http://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean\\_squared\\_error.html](http://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_squared_error.html)
- [24] PCA d'Scikit-learn [Online].  
Disponible: <http://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>
- [25] Diagrama de caixes - Wikipedia [Online].  
Disponible: [https://en.wikipedia.org/wiki/Box\\_plot](https://en.wikipedia.org/wiki/Box_plot)
- [26] Matriu de confusió - Wikipedia [Online].  
Disponible: [https://en.wikipedia.org/wiki/Confusion\\_matrix](https://en.wikipedia.org/wiki/Confusion_matrix)